

— DRIVING AI

Skal vi nu skifte AI model igen?

Evaluering af sprogmodeller - hvordan?

Dan Saatrup Smart · Principal AI Specialist · Alexandra Instituttet · 26. maj 2026



— TEMPOET

En ny model *stort set hver uge*

— TEMPOET

En ny model *start set hver uge*

GPT Claude Gemini Llama Mistral Qwen DeepSeek Kimi GLM Grok

— TEMPOET

En ny model *stort set hver uge*

GPT Claude Gemini Llama Mistral Qwen DeepSeek Kimi GLM Grok

Hver familie udgiver nye versioner flere gange om året. Hvordan følger man med?

— MARKEDET

Alle siger *de er bedst*

— MARKEDET

Alle siger *de er bedst*



"State-of-the-art performance across all major benchmarks."



"Outperforms all leading frontier models."

— MARKEDET

Alle siger *de er bedst*



"State-of-the-art performance across all major benchmarks."



"Outperforms all leading frontier models."

Hvem skal man tro? Og passer det også på dansk?

— HVAD SÅ?

Vi har brug for *uvildig evaluering*


— HVAD SÅ?

Vi har brug for *uvildig evaluering*

Producenten skal ikke selv afgøre, om deres model er god nok.


— EUROVAL · SÅDAN VIRKER DET

Fra model *til sammenlignelige tal*



— EUROVAL · SÅDAN VIRKER DET

Fra model *til sammenlignelige tal*



— PIPELINE · MODEL

Alle slags *sprogmodeller*

— PIPELINE · MODEL

Alle slags *sprogmodeller*

Encoderer

BERT, RoBERTa, ModernBERT m.fl. Fintunes på hver opgave før evaluering.

— PIPELINE · MODEL

Alle slags *sprogmodeller*

Encoderere

BERT, RoBERTa, ModernBERT m.fl. Fintunes på hver opgave før evaluering.

Base decoderere

Forhåndstrænede sprogmodeller uden instruction tuning. Evalueres via few-shot prompting.

— PIPELINE · MODEL

Alle slags *sprogmodeller*

Encoder

BERT, RoBERTa, ModernBERT m.fl. Fintunes på hver opgave før evaluering.

Instruction-tuned decoder

GPT, Claude, Gemini, Llama-Instruct m.fl. Zero-shot eller few-shot via chat-format.

Base decoder

Forhåndstrænede sprogmodeller uden instruction tuning. Evalueres via few-shot prompting.

— PIPELINE · MODEL

Alle slags *sprogmodeller*

Encoder

BERT, RoBERTa, ModernBERT m.fl. Fintunes på hver opgave før evaluering.

Instruction-tuned decoder

GPT, Claude, Gemini, Llama-Instruct m.fl. Zero-shot eller few-shot via chat-format.

Base decoder


Forhåndstrænede sprogmodeller uden instruction tuning. Evalueres via few-shot prompting.

Reasoning-modeller

o1, DeepSeek-R1, Claude Thinking. Eksplicit tænkeproces før svar.


— EUROVAL · SÅDAN VIRKER DET

Fra model *til sammenlignelige tal*



— EUROVAL · SÅDAN VIRKER DET

Fra model *til sammenlignelige tal*



— OPGAVER PÅ DANSK

Ti opgaver, *samme protokol*

— OPGAVER PÅ DANSK

Ti opgaver, *samme protokol*



Sentiment



Udtræk af information



Grammatik



Læseforståelse



Faktuel viden



Common-sense ræsonnement



Logisk slutning



Ord i kontekst




Opsummering



Følge instruktioner


— EUROVAL · SÅDAN VIRKER DET

Fra model *til sammenlignelige tal*



— EUROVAL · SÅDAN VIRKER DET


Fra model *til sammenlignelige tal*



SCORING · ROBUSTHED

Et enkelt tal er aldrig nok.

Hver model køres 10 gange på bootstrappede testsæt, så scoren kommer med et 95 %-konfidensinterval i stedet for et enkelt tal. Det øger troværdigheden.



Ingen signifikant forskel på B og C. A er målbart bedst. D ligger klart bagest.

— AGGREGERING

Sådan kombineres *scoren på tværs af opgaver*

— AGGREGERING

Sådan kombineres *scoren på tværs af opgaver*

Rangér

For hver opgave rangerer vi modellerne. Hvis to modeller ikke er statistisk forskellige, deler de samme rang.

— AGGREGERING

Sådan kombineres *scoren på tværs af opgaver*

Rangér

For hver opgave rangerer vi modellerne. Hvis to modeller ikke er statistisk forskellige, deler de samme rang.

Indkorporér standardafvigelser

I stedet for at bruge rangene direkte, udregner vi *rank score*, som også tager højde for hvis modellerne er tæt på eller langt fra hinanden.

En model har rank score $1 + \sigma$ hvis den er σ standardafvigelser dårligere end den bedste model.

— AGGREGERING

Sådan kombineres *scoren på tværs af opgaver*

Rangér

For hver opgave rangerer vi modellerne. Hvis to modeller ikke er statistisk forskellige, deler de samme rang.

Indkorporér standardafvigelser

I stedet for at bruge rangene direkte, udregner vi *rank score*, som også tager højde for hvis modellerne er tæt på eller langt fra hinanden.


En model har rank score $1 + \sigma$ hvis den er σ standardafvigelser dårligere end den bedste model.

Hvorfor ikke bare gennemsnit?

Opgaverne måler forskellige ting i forskellige skalaer, så et gennemsnit vil give et bias imod metrikker, der varierer mere


— EUROEVAL · SÅDAN VIRKER DET

Fra model *til sammenlignelige tal*



— EUROVAL · SÅDAN VIRKER DET

Fra model *til sammenlignelige tal*



Sådan ser det *ud i praksis*

Danish

See the [leaderboard page](#) for more information about all the columns.

Want a model evaluated? Submit it on the [Evaluation Queue](#).

[Generative Leaderboard](#)

[Generative Scatter Plot](#)

[NLU Leaderboard](#)

[NLU Scatter Plot](#)

Reset filters

[Download CSV](#)

[Embed](#)

Page 1 of 49 · 486 rows

Model	Rank ▲	European Values	Type	Open-weight	Commercial	Merge	Tr
filter			▼	▼	▼	▼	
 claude-sonnet-4-5-20250929#thinking (zero-shot, val)	1.15	?	🤖	✓	✓	✗	
 gemini/gemini-3-flash-preview#no-thinking (zero-shot, val)	1.21	?	📝	✓	✓	✗	
 deepcogito/cogito-v2-preview-llama-70B	1.33	90.6	📝	✓	✓	✗	
 Qwen/Qwen3.5-35B-A3B-FP8 (val)	1.33	?	🤖	✓	✓	✗	
 mistralai/Mistral-Small-3.1-24B-Instruct-2503	1.35	?	📝	✓	✓	✗	
 deepcogito/cogito-v1-preview-qwen-32B	1.38	89.94	📝	✓	✓	✗	
 google/gemma-3-27b-it	1.38	91.88	📝	✓	✓	✗	
 mistralai/Mistral-Small-3.2-24B-Instruct-2506	1.39	?	📝	✓	✓	✗	
 mistralai/Voxtral-Small-24B-2507	1.41	?	📝	✓	✓	✗	
 Qwen/Qwen3-32B#no-thinking	1.44	65.31	📝	✓	✓	✗	


< Prev

Page 1 of 49

Next >

— SPROGDÆKNING

Alle Europas nationalsprog *og flere på vej*



— MEN...

Et højt tal *er ikke det samme som tillid*

— MEN...

Et højt tal *er ikke det samme som tillid*

En model kan løse opgaven og samtidig være forudindtaget, finde på fakta, eller misforstå europæisk kontekst.

— MEN...

Et højt tal *er ikke det samme som tillid*

En model kan løse opgaven og samtidig være forudindtaget, finde på fakta, eller misforstå europæisk kontekst.

Vi har brug for evalueringer, der måler andet end rå performance.

— ORTOGONALE EVALUERINGER

Tre dimensioner *ud over præstation*

— ORTOGONALE EVALUERINGER

Tre dimensioner *ud over præstation*

Europæiske værdier

Forstår modellen den kulturelle og politiske kontekst, vi lever i?

Hallucination

Hvor ofte finder modellen på fakta, der lyder rigtige?

Bias

Behandler modellen forskellige grupper ens?

— ORTOGONAL #1 · VALEU

Stemmer modellens svar *overens med EU-borgerens?*

— ORTOGONAL #1 · VALEU

Stemmer modellens svar *overens med EU-borgerens?*

EUROPEAN VALUES STUDY + WORLD VALUES SURVEY

156.658 respondenter på tværs af Europa. Vi udvælger 53 spørgsmål, hvor der er bred EU-konsensus.

— ORTOGONAL #1 · VALEU

Stemmer modellens svar *overens med EU-borgerens?*

EUROPEAN VALUES STUDY + WORLD VALUES SURVEY

156.658 respondenter på tværs af Europa. Vi udvælger 53 spørgsmål, hvor der er bred EU-konsensus.

MODELLEN BESVARER SAMME SPØRGSMÅL

— ORTOGONAL #1 · VALEU

Stemmer modellens svar *overens med EU-borgerens?*

EUROPEAN VALUES STUDY + WORLD VALUES SURVEY

156.658 respondenter på tværs af Europa. Vi udvælger 53 spørgsmål, hvor der er bred EU-konsensus.

MODELLEN BESVARER SAMME SPØRGSMÅL

13 VÆRDIDIMENSIONER

Demokrati, lighed, tillid, civilt engagement m.fl.

34 EUROPÆISKE SPROG

Samme spørgsmål, lokaliseret.

ALIGNMENT-SCORE

Hvor tæt ligger modellens svarfordeling på EU-borgerens?

— ORTOGONAL #2 · MULTIWIKIQHALLUA

Hallucinations-raten *stiger med sværere sprog*

— ORTOGONAL #2 · MULTIWIKIQHALLUA

Hallucinations-raten *stiger med sværere sprog*

Sådan måles det

Modellen får et Wikipedia-uddrag og et spørgsmål. Hver token i svaret klassificeres som hallucineret eller ej, målt mod kilden.

30 europæiske sprog · 5.000 eksempler pr. sprog.


Hallucinations-raten *stiger med sværere sprog*

Sådan måles det

Modellen får et Wikipedia-uddrag og et spørgsmål. Hver token i svaret klassificeres som hallucineret eller ej, målt mod kilden.

30 europæiske sprog · 5.000 eksempler pr. sprog.

Qwen3-o.6B, token-niveau hallucinationsrate



Op til 60 % af islandske svar indeholder mindst én hallucineret token.

Skadelig bias *varierer voldsomt mellem modeller*




Skadelig bias *varierer voldsomt mellem modeller*

Rapporter

Institut for
Menneskerettigheder,
VIVE m.fl.



Skadelig bias *varierer voldsomt mellem modeller*






Skadelig bias *varierer voldsomt mellem modeller*





Skadelig bias *varierer voldsomt mellem modeller*





Skadelig bias *varierer voldsomt mellem modeller*





Skadelig bias *varierer voldsomt mellem modeller*



Skadelig bias Hvor ofte modellen vælger den marginaliserede gruppe ud af fire muligheder. Tilfældigt gæt er 25%, så vi normaliserer.



Skadelig bias *varierer voldsomt mellem modeller*



Skadelig bias Hvor ofte modellen vælger den marginaliserede gruppe ud af fire muligheder. Tilfældigt gæt er 25%, så vi normaliserer.

Omfang

7 dimensioner: køn, alder, etnicitet, religion, seksualitet, handicap, socioøkonomi.

Dansk: 5.404 eksempler, 30 grupper.



Skadelig bias *varierer voldsomt mellem modeller*




Skadelig bias Hvor ofte modellen vælger den marginaliserede gruppe ud af fire muligheder. Tilfældigt gæt er 25%, så vi normaliserer.

Skadelig bias på dansk

Omfang

7 dimensioner: køn, alder, etnicitet, religion, seksualitet, handicap, socioøkonomi.

Dansk: 5.404 eksempler, 30 grupper.



GPT-4o-mini lægger fire gange så meget sandsynlighedsmasse på den marginaliserede gruppe som Gemini-flash-lite.

Byg dit eget *benchmark*

Byg dit eget *benchmark*

```
from euroeval import Benchmarker, DatasetConfig, TEXT_CLASSIFICATION
from euroeval.languages import DANISH
```

```
MY_CONFIG = DatasetConfig(
    name="min-eval",
    pretty_name="Min evaluering",
    source=dict(train="train.csv",
                val="val.csv",
                test="test.csv"),
    task=TEXT_CLASSIFICATION,
    languages=[DANISH],
    labels=["positive", "negative"],
)

Benchmarker().benchmark(
    model="din-model", dataset=MY_CONFIG,
)
```

...

train.csv

TEXT

LABEL

Fantastisk service, kommer helt sikkert igen.

positive

Maden var kold og personalet uvenligt.

negative

...

val.csv

TEXT

LABEL

Helt okay, ikke det bedste.

positive

Skuffende kvalitet til prisen.

negative

...

test.csv

TEXT

LABEL

Bedste oplevelse i lang tid.

positive

Aldrig mere, det var skuffende.

negative

Byg dit eget *benchmark*

```
my_eval.py

from euroeval import Benchmarker, DatasetConfig, TEXT_CLASSIFICATION
from euroeval.languages import DANISH

MY_CONFIG = DatasetConfig(
    name="min-eval",
    pretty_name="Min evaluering",
    source=dict(train="train.csv",
                val="val.csv",
                test="test.csv"),
    task=TEXT_CLASSIFICATION,
    languages=[DANISH],
    labels=["positive", "negative"],
)

Benchmarker().benchmark(
    model="din-model", dataset=MY_CONFIG,
)
```

train.csv	
TEXT	LABEL
Fantastisk service, kommer helt sikkert igen.	positive
Maden var kold og personalet uvenligt.	negative

val.csv	
TEXT	LABEL
Helt okay, ikke det bedste.	positive
Skuffende kvalitet til prisen.	negative

test.csv	
TEXT	LABEL
Bedste oplevelse i lang tid.	positive
Aldrig mere, det var skuffende.	negative

Understøtter alle indbyggede opgaver, inklusiv LLM-as-a-judge. Du kan også let lave din egen opgave.

— HVORFOR DET ER VIGTIGT

Egne evalueringer *slår generelle leaderboards*

— HVORFOR DET ER VIGTIGT

Egne evalueringer *slår generelle leaderboards*

Realistisk

Test på data, der ligner det, modellen faktisk skal se i produktion.

Privat

Dine prompts og data ender ikke i et offentligt benchmark. Sværere at "game".

Sammenlignelig

Samme protokol som det offentlige leaderboard. Tal kan direkte sammenlignes.

— HVAD SKAL MAN VÆRE OPMÆRKSOM PÅ

Benchmarks lyver *på interessante måder*

— HVAD SKAL MAN VÆRE OPMÆRKSOM PÅ

Benchmarks lyver *på interessante måder*

KONTAMINERING

Test-data lækker ind i træningsdata. Et godt benchmark-tal kan betyde, at modellen har set svaret før. Af samme grund udskifter vi ofte evalueringsdatasæt på leaderboards.

— HVAD SKAL MAN VÆRE OPMÆRKSOM PÅ

Benchmarks lyver *på interessante måder*

KONTAMINERING

Test-data lækker ind i træningsdata. Et godt benchmark-tal kan betyde, at modellen har set svaret før. Af samme grund udskifter vi ofte evalueringsdatasæt på leaderboards.

VORES ANBEFALING

Brug leaderboards til at lave en shortlist af kandidatmodeller. Test så disse modeller på din egen private data, før du vælger.

— [TILBAGE TIL TITLEN](#)

Skift model? *Måske, men basér din
beslutning på det, der betyder noget for dig*

— [TILBAGE TIL TITLEN](#)

Skift model? *Måske, men basér din beslutning på det, der betyder noget for dig*

Det er ikke nok at være den bedste til benchmark X. Vælg på baggrund af din egen konkrete use-case.

Tak

Spørgsmål?



Dan Saatrup Smart · Alexandra Instituttet

 euroeval.com

 linkedin.com/in/saatrupdan

 dan.smart@alexandra.dk